

Integrasi YOLOv8 dan *BlazePose* dalam Estimasi Jarak Objek Manusia *Real-Time* berbasis *Stereo Triangulation*

Alif Bimo Rizky Ghaniya¹, Amelia Ragil Susanti Putri², Bintang Anugerah Baihaqi³, Harby Izza Ma'had Mahardika⁴, Reza Gusti Eka Prasetya⁵

*Prodi Perkeretaapian, Jurusan Teknik, Politeknik Negeri Madiun
Jalan Ring Road Barat, Winongo, Kecamatan Manguharjo, Kota Madiun, Jawa Timur 63162*

Abstract - Real-time human object distance estimation is an important requirement in various applications such as security systems, smart transportation, and human-computer interaction. This research implements the integration of the YOLOv8 (You Only Look Once version 8) algorithm for human object detection and BlazePose for body pose estimation, combined with a stereo vision triangulation approach using two cameras. The system is designed to detect the human position and body pose key points from two camera viewpoints, and then calculate the object distance based on the obtained disparity. The system's evaluation is conducted by comparing the distance estimation results with manual measurements, which show that the integration of YOLOv8 and BlazePose can provide accurate distance estimations with an acceptable error margin. The system testing involves camera calibration, object detection using YOLOv8, body pose estimation with BlazePose, and distance calculation using triangulation. The results of both static and dynamic testing show that the system can detect human objects and body poses effectively, as well as provide fairly accurate distance estimations. However, the accuracy of the distance estimation is influenced by factors such as the object's position, distance, and movement. This system holds great potential in the development of real-time computer vision-based monitoring technologies.

Keywords – YOLOv8, BlazePose, Distance Estimation, Stereo Triangulation, Human Detection

Abstrak – Estimasi jarak objek manusia secara *real-time* merupakan kebutuhan penting dalam berbagai aplikasi seperti sistem keamanan, transportasi cerdas, dan interaksi manusia-komputer. Penelitian ini menerapkan integrasi algoritma YOLOv8 (*You Only Look Once version 8*) untuk deteksi objek manusia dan *BlazePose* untuk estimasi pose tubuh, yang dikombinasikan dengan pendekatan triangulasi *stereo vision* menggunakan dua kamera. Sistem ini dirancang untuk mendeteksi posisi manusia dan titik-titik pose tubuh dari dua sudut pandang kamera, kemudian menghitung jarak objek berdasarkan disparitas yang diperoleh. Evaluasi sistem dilakukan dengan membandingkan hasil estimasi jarak dengan pengukuran manual, yang menunjukkan bahwa integrasi YOLOv8 dan *BlazePose* mampu memberikan estimasi jarak yang akurat dengan tingkat kesalahan yang dapat diterima. Pengujian sistem melibatkan kalibrasi kamera, deteksi objek menggunakan YOLOv8, estimasi pose tubuh dengan *BlazePose*, dan perhitungan jarak menggunakan triangulasi. Hasil pengujian statis dan dinamis menunjukkan bahwa sistem dapat mendeteksi objek dan pose tubuh manusia dengan baik, serta memberikan estimasi jarak yang cukup akurat. Meskipun demikian, akurasi estimasi jarak dipengaruhi oleh faktor-faktor seperti posisi objek, jarak, dan gerakan. Sistem ini memiliki potensi besar dalam pengembangan teknologi pemantauan berbasis *visi komputer* secara *real-time*.

Kata kunci – YOLOv8, BlazePose, Estimasi Jarak, Triangulasi Stereo, Deteksi Manusia

I. PENDAHULUAN

Kemampuan sistem dalam memperkirakan jarak objek secara akurat menjadi hal yang sangat penting dalam pengembangan teknologi berbasis persepsi visual, terutama pada sistem kendaraan otonom, pengawasan cerdas, dan robotika [1]. Salah satu metode yang umum digunakan adalah sistem *Stereo Vision*, yang

memanfaatkan dua kamera untuk menangkap gambar dari dua sudut pandang yang berbeda.

Dalam konteks deteksi objek manusia, YOLO (*You Only Look Once*) telah terbukti menjadi algoritma yang sangat efektif untuk deteksi objek secara cepat dan akurat. *You Only Look Once* (YOLO) merupakan sebuah metode pendekatan baru yang digunakan dalam pendeteksian objek dengan target dapat digunakan untuk pemrosesan secara *real time* [3]. Cara kerja

YOLO yakni dengan cara membingkai objek yang terdeteksi sebagai masalah regresi tunggal dari piksel gambar langsung ke kotak pembatas (*bounding box*) spasial yang terpisah pada probabilitas kelas yang telah dideklarasikan. YOLO mempunyai prinsip kerja yakni membagi gambar *input* menjadi piksel lebih kecil menjadi grid $S \times S$ dengan setiap 40 sel grid dapat mendeteksi *bounding box* sehingga didapatkan nilai keyakinan (*confidence score*) [5]. YOLOv8 muncul sebagai evolusi terbaru dalam seri YOLO, yang dikembangkan oleh Ultralytics pada tahun 2023. YOLOv8 merupakan penyempurnaan dan perluasan ide-ide yang diperkenalkan dalam YOLOv5, dengan penekanan pada peningkatan akurasi model dan kegunaan untuk tugas deteksi objek waktu nyata.

Human Pose Estimation (HPE) adalah suatu teknik dalam bidang visi komputer yang bertujuan untuk mendeteksi dan memperkirakan posisi berbagai bagian tubuh manusia dalam gambar atau video. HPE digunakan untuk mengenali contoh orang yang berbeda di dalam data multimedia (gambar RGB, video, sinyal RF, atau radar) yang direkam oleh sensor, dan untuk melokalisasi satu set yang 23 telah ditentukan sebelumnya untuk setiap orang [2]. Proses ini melibatkan identifikasi titik-titik kunci pada tubuh, seperti sendi-sendi, yang memungkinkan analisis lebih lanjut mengenai postur, gerakan, dan perilaku individu.

Di sisi lain, *BlazePose*, sebuah model untuk estimasi pose tubuh manusia, dapat memantau pergerakan tubuh manusia dan mengidentifikasi pose tubuh yang sangat penting dalam aplikasi yang melibatkan interaksi manusia. *BlazePose* merupakan salah satu metode *Human Pose Estimation* yang memiliki 33 3D Landmark yang didapatkan dari segmentasi background dan 24 mendapat objek tubuh dari RGB frame [7]. Cara kerja *BlazePose* adalah mengintegrasikan mekanisme deteksi bagian tubuh manusia menggunakan *Confidence Maps* dan *Part Affinity Fields* (PAFs). *Confidence Maps* merepresentasikan kepercayaan deteksi terhadap lokasi sendi-sendi tubuh dalam citra, sedangkan PAFs menggambarkan hubungan spasial antara bagian tubuh.

Integrasi antara YOLO untuk deteksi objek dan *BlazePose* untuk estimasi pose tubuh, dikombinasikan dengan pendekatan triangulasi *stereo vision*, menghasilkan sistem yang tidak hanya dapat mendeteksi manusia, tetapi juga mengestimasi jaraknya dengan akurat dari dua perspektif kamera yang berbeda [6]. Sistem ini bekerja dengan mendeteksi posisi manusia dan titik-titik pose tubuh dari dua kamera secara bersamaan, kemudian menghitung jarak objek


berdasarkan disparitas yang terukur menggunakan prinsip triangulasi. Evaluasi dilakukan dengan membandingkan hasil estimasi jarak sistem terhadap jarak aktual objek menggunakan alat ukur manual.

II. METODOLOGI

Pengujian ini dilakukan dengan menggunakan sistem YOLOv8 untuk deteksi objek, *BlazePose* untuk pendeteksian pose manusia, serta perhitungan estimasi jarak melalui metode *stereo triangulation*, yang didahului dengan tahapan kalibrasi kamera stereo dan akuisisi citra.

A. YOLO (You Only Look Once)v8

YOLO (You Only Look Once) adalah salah satu algoritma object detection yang dapat mendeteksi objek pada gambar atau video secara real-time.



Gambar 1. Arsitektur YOLOv8


YOLOv8 memperkenalkan penyempurnaan lebih lanjut dalam arsitektur deteksi objek, yang meningkatkan efisiensi dan akurasi model. Integrasi *backbone* CSPDarknet yang ditingkatkan dan arsitektur PANet++ neck memungkinkan ekstraksi dan agregasi fitur yang lebih baik. Modifikasi ini mengatasi masalah 50 redundansi gradien dan mengoptimalkan jaringan piramida fitur, yang berkontribusi pada model yang lebih ramping dan efektif.



Gambar 2. Contoh YOLOv8

B. BlazePose

Sementara, *BlazePose* merupakan salah satu metode dari *Human Pose Estimation*. Keunggulan utama *Blazepose* yaitu kemampuan estimasi pose yang akurat dalam waktu yang cepat, membuatnya ideal untuk aplikasi *real time* seperti *gaming*, *augmented reality*, dan pemantauan gerakan manusia. Arsitektur *BlazePose* memiliki *landmarks* terdiri dari 33 *keypoints* yang mendefinisikan titik kunci dan titik sendi tubuh manusia. *Keypoints* tersebut mencakup seluruh tubuh manusia mulai dari kepala hingga kaki dengan seimbang. Berikut arsitektur *landmarks BlazePose*:




Gambar 3. Pose Landmarks BlazePose

Pada *landmarks* yang ditunjukkan oleh Gambar memiliki bagian-bagian tersendiri pada masing-masing *landmarks*. Berikut merupakan keterangan *landmarks* BlazePose:

0. nose	17. left_pinky
1. left_eye_inner	18. right_pinky
2. left_eye	19. left_index
3. left_eye_outer	20. right_index
4. right_eye_inner	21. left_thumb
5. right_eye	22. right_thumb
6. right_eye_outer	23. left_hip
7. left_ear	24. right_hip
8. right_ear	25. left_knee
9. mouth_left	26. right_knee
10. mouth_right	27. left_ankle
11. left_shoulder	28. right_ankle
12. right_shoulder	29. left_heel
13. left_elbow	30. right_heel
14. right_elbow	31. left_foot_index
15. left_wrist	32. right_foot_index
16. right_wrist	

Berikut hasil pendeteksian pose tubuh dengan *BlazePose*, yang menampilkan struktur kerangka berdasarkan titik-titik utama tubuh.




Gambar 4. Hasil BlazePose

C. Stereo Triangulation

Stereo triangulation adalah metode untuk menghitung jarak (kedalaman) suatu objek dari kamera dengan menggunakan dua citra (gambar) yang diambil dari dua sudut pandang berbeda, seperti mata kiri dan kanan pada manusia [4]. Prinsip kerjanya didasarkan pada geometri segitiga, jika posisi relatif dua kamera diketahui (hasil dari kalibrasi stereo), dan objek yang sama dapat diidentifikasi pada kedua gambar, maka dengan membandingkan perbedaan posisi (*disparity*) objek tersebut dalam kedua citra, sistem dapat menghitung seberapa jauh objek berada dari kamera.

D. Kalibrasi Kamera

Kalibrasi kamera bertujuan untuk memperoleh parameter intrinsik dan ekstrinsik dari masing-masing kamera. Proses kalibrasi dilakukan dengan menempatkan papan *checkerboard* di berbagai sudut pandang dan posisi untuk memperoleh parameter intrinsik serta ekstrinsik dari masing-masing kamera. Hasil kalibrasi kemudian dijalankan untuk menguji konsistensi dan akurasi parameter yang diperoleh.



Gambar 5. Mengkalibrasikan Dua Kamera

Tahap berikutnya adalah pengambilan citra stereo menggunakan dua kamera yang dipasang sejajar pada jarak tertentu sesuai konfigurasi kalibrasi. YOLO digunakan untuk mendeteksi objek manusia, sedangkan *BlazePose* digunakan untuk mendeteksi titik-titik pose manusia secara lebih detail.



Gambar 6. Mengukur Jarak Antar Lensa

Setelah objek dikenali dalam kedua citra, sistem melakukan pencocokan posisi piksel objek yang sama dari gambar kiri dan kanan untuk menghitung disparitas (perbedaan posisi). Berdasarkan nilai disparitas dan parameter hasil kalibrasi, perhitungan jarak dilakukan menggunakan metode triangulasi. Terakhir, hasil estimasi jarak divalidasi dengan pengukuran jarak aktual menggunakan alat ukur konvensional. Perbandingan antara hasil estimasi dan jarak sebenarnya digunakan untuk menghitung tingkat akurasi dan tingkat kesalahan (*error rate*) dari sistem.



Gambar 7. Mengukur Jarak Lensa Kamera dengan Objek

E. Triangulasi (*Triangulation*)

Konsep triangulasi pada dasarnya adalah perpotongan dua buah garis yang jika dipanjangkan akan bertemu pada suatu titik tertentu. Proses triangulasi pada dasarnya melibatkan pencocokan titik-titik yang terlihat pada suatu gambar untuk menentukan posisi tiga dimensi suatu objek. Berdasarkan konsep dari *multiple view geometry*, jarak objek ke kamera dapat diperoleh dari dua *view* yang berbeda, dengan konsep seperti ini, maka pada sistem ini kita menggunakan pendekatan triangulasi untuk menemukan titik potong *depth* atau koordinat sumbu Z dari suatu objek terhadap dua *view* berbeda.

III. HASIL DAN PEMBAHASAN

Pengujian sistem dilakukan secara bertahap, dimulai dari proses kalibrasi kamera hingga estimasi jarak terhadap objek manusia secara *real-time*. Tahap awal berupa kalibrasi kamera stereo menggunakan pola *checkerboard* hitam putih untuk memperoleh parameter intrinsik dan ekstrinsik dari masing-masing kamera. Kalibrasi dilakukan dengan mengambil citra *checkerboard* dari berbagai sudut dan jarak.

Setelah kamera dikalibrasi, dilakukan pengukuran jarak antar kamera secara manual seperti pada Gambar 7, untuk memastikan *baseline* yang menjadi dasar perhitungan triangulasi. Dua kamera yang dipasang sejajar dengan jarak antar lensa (*baseline*) sebesar 9 cm. Gambar kiri dan kanan kemudian diproses untuk mendeteksi objek menggunakan model YOLO dan mendeteksi titik-titik kunci tubuh manusia menggunakan *BlazePose*.

3. 1 Hasil YOLOv8


Hasil dari YOLOv8 menunjukkan bahwa algoritma ini mampu mendeteksi objek secara langsung (*real-time*) dengan cukup akurat. Deteksi ini dilakukan menggunakan arsitektur YOLOv8 yang sudah ditingkatkan, yaitu dengan menggunakan *backbone* CSPDarknet dan *neck* PANet++, sehingga fitur dari gambar bisa diambil dengan lebih baik dan akurat. Sistem ini bekerja dengan membagi gambar menjadi beberapa bagian (*grid*), lalu setiap bagian menghitung kemungkinan adanya objek. Hasil ini menunjukkan bahwa YOLOv8 tidak hanya bisa mendeteksi manusia sebagai objek utama, tapi juga mampu mengenali objek lain di sekitarnya dengan tingkat keakuratan yang tinggi.

Gambar 8. Hasil YOLOv8 objek *person*Gambar 9. Hasil YOLOv8 objek *chair*Gambar 10. Hasil YOLOv8 objek *cell phone*

Hasil dari ketiga gambar menunjukkan hasil deteksi objek yang berbeda menggunakan algoritma YOLOv8. Pada Gambar 8, sistem berhasil mendeteksi objek manusia (*person*) dengan jelas dan memberikan label yang sesuai. Gambar 9 memperlihatkan bahwa YOLOv8 juga mampu mengenali objek berupa kursi (*chair*) secara akurat. Selanjutnya, pada Gambar 10, sistem mendeteksi objek ponsel (*cell phone*) meskipun ukurannya lebih kecil dibanding objek lainnya. Hasil ini membuktikan bahwa YOLOv8 dapat mendeteksi berbagai jenis objek dengan baik, baik manusia maupun benda di sekitarnya, sehingga cocok digunakan dalam sistem pengolahan citra untuk aplikasi seperti estimasi jarak.

3.2 Hasil *Human Pose Estimation* Metode *Blazepose*

Arsitektur *BlazePose* memiliki *landmarks* yang berjumlah 33 *keypoints* dimana mendefinisikan titik kunci dan juga titik-titik sendi pada tubuh manusia. 33 *keypoints* ini mencakup dari kepala hingga kaki manusia dengan seimbang. Hasil dari pose estimation dapat dilihat pada Gambar 11,12.

Gambar 11. Hasil *Blazepose* Jarak 2 meterGambar 12. Hasil *Blazepose* Jarak 5 meter

Hasil dari keduanya menampilkan proses *estimating pose* manusia dapat menemukan letak *keypoints* dari objek manusia yang terdeteksi dengan baik sehingga menghasilkan total 33 *keypoints* yakni sesuai dengan fundamental pose yang dimiliki oleh *BlazePose* pada gestur manusia yang jelas menghadap ke kamera dan memperlihatkan seluruh anggota tubuh manusia sehingga seluruh *landmarks* dari *Human Pose Estimation* ini dapat ditampilkan secara menyeluruh.

Pada Gambar 11 dengan jarak 2 meter, detail koordinat titik-titik sendi (*keypoints*) dapat terlihat lebih jelas dan akurat, ditandai dengan ukuran tubuh yang lebih besar dalam tampilan serta koordinat (x, y, z) yang lebih terdefinisi untuk

setiap titik tubuh. Sementara itu, Gambar 12 menampilkan hasil deteksi dengan metode yang sama, namun dari jarak sekitar 5 meter. Pada jarak ini, meskipun keseluruhan pose masih dapat dikenali, akurasi detail titik-titik tubuh sedikit berkurang karena resolusi tubuh yang tampak lebih kecil dan pengaruh jarak terhadap persepsi kedalaman oleh kamera stereo. Kedua gambar ini menunjukkan bagaimana jarak memengaruhi presisi pendeteksian pose menggunakan *BlazePose*.

Pengambilan koordinat pada contoh pose yang ditampilkan pada Gambar 8 dapat dilihat dari nilai koordinat x, y, dan z yang dihasilkan dari masing-masing *keypoints* seperti yang ditampilkan pada Tabel 1


Table 1. Hasil plot koordinat dari landmarks

Keypoint	x	y	z
0	0.555746	0.06038	-0.337536
1	0.566523	0.039958	-0.311458
2	0.571512	0.040677	-0.311541
3	0.57639	0.041528	-0.311539
4	0.546408	0.037685	-0.310911
5	0.539526	0.037416	-0.310894
6	0.532212	0.037502	-0.310873
7	0.584787	0.051312	-0.138499
8	0.523551	0.046917	-0.137079
9	0.565655	0.088655	-0.271412
10	0.541134	0.087122	-0.271094
11	0.62717	0.194364	-0.037179
12	0.467306	0.184522	-0.013691
13	0.654961	0.328931	-0.129453
14	0.423004	0.330648	-0.109256
15	0.644062	0.324748	-0.478326
16	0.431905	0.313652	-0.47554
17	0.626404	0.333559	-0.553465
18	0.448141	0.3234	-0.547979
19	0.620046	0.307184	-0.573488
20	0.455434	0.294865	-0.565059
21	0.622142	0.303549	-0.492173
22	0.454783	0.290427	-0.489389
23	0.58368	0.504396	-0.002246
24	0.491172	0.496192	0.002302
25	0.57201	0.726067	-0.006083
26	0.483499	0.72209	0.012577
27	0.566828	0.905057	0.332249
28	0.490603	0.898878	0.303667
29	0.554015	0.926685	0.353552
30	0.50318	0.925327	0.322169
31	0.575354	0.98062	0.168279
32	0.473124	0.97988	0.131012

3.3. Hasil Gabungan YOLO dan *Blazepose* dengan *Stereo Triangulation*

YOLO berperan sebagai detektor objek yang mendeteksi keberadaan manusia dalam citra secara cepat dan efisien. Setelah objek manusia terdeteksi, *BlazePose* digunakan untuk mengekstraksi 33 titik sendi (*keypoints*) pada tubuh, termasuk bagian wajah, bahu, siku, tangan, pinggul, lutut, hingga telapak kaki, yang divisualisasikan dalam bentuk kerangka tubuh (*skeleton*). Setiap *keypoint* yang dihasilkan memiliki nilai koordinat spasial (x, y, z) dan nilai kepercayaan atau nilai akurasi.


Metode *stereo triangulation* kemudian digunakan untuk menghitung posisi absolut dari setiap *keypoint* dalam ruang 3D, berdasarkan perbedaan posisi titik dari dua sudut pandang kamera (kiri dan kanan) perhitungan ini menghasilkan estimasi jarak (*depth*) setiap titik terhadap kamera.



(a)



(b)



(c)

Gambar 13. Hasil Stereo Triangulation

Ketiga gambar di atas menunjukkan hasil visualisasi gabungan dari deteksi objek menggunakan YOLO dan estimasi pose tubuh dengan *BlazePose*, yang kemudian diolah menggunakan metode *stereo triangulation*. Pada gambar (a), tampak seseorang sedang berdiri sambil melihat ponsel, dengan titik-titik sendi pada tubuhnya berhasil terdeteksi dan divisualisasikan dalam bentuk skeleton. Gambar (b) memperlihatkan seseorang dalam posisi mengangkat tangan kanan, dan sistem tetap mampu mengenali seluruh titik sendi meskipun terjadi perubahan pose. Sedangkan pada gambar (c), seseorang terlihat dalam posisi membungkuk atau menunduk sambil memegang ponsel, dan sistem tetap mendeteksi semua keypoint dengan baik. Visualisasi ini menunjukkan bahwa sistem gabungan ini mampu mendeteksi dan melacak postur tubuh manusia dalam berbagai pose dan sudut pandang, serta menghasilkan estimasi jarak 3D dari setiap titik dengan cukup stabil.

3.4. Hasil Pengujian Statis


Pengujian statis bertujuan untuk mengevaluasi performa sistem deteksi dan estimasi jarak objek (orang) dalam kondisi kamera diam (tidak bergerak), sementara objek berada dalam posisi tetap namun pada jarak berbeda dari kamera. Fokus utama adalah akurasi *Human Pose Estimation* (HPE) dan akurasi estimasi jarak dari sistem berbasis YOLO + *BlazePose* + triangulasi.

Langkah Pengujian :

- 1) Kamera stereo diletakkan secara tetap.
- 2) Objek berupa orang ditempatkan pada jarak bervariasi


- 3) Setiap posisi diuji beberapa kali untuk mendapatkan data akurasi.
- 4) Sistem dijalankan dan menghasilkan:
 - Bounding box & label untuk objek.
 - *Human Pose Estimation* dengan titik tubuh.
 - Estimasi jarak dalam meter.
- 5) Hasil ditampilkan langsung di layar (overlay informasi).

Hasil pengujian statis dapat dilihat pada gambar berikut.




(a)

Sistem berhasil mendeteksi objek manusia dengan tingkat akurasi *Human Pose Estimation* (HPE) sebesar 93.94% dan performa sebesar 0.94. Estimasi jarak objek manusia terhadap kamera adalah 1.30 meter. Akan tetapi, bounding box dan titik-titik pose tubuh kurang lengkap karena ada bagian sendi (*keypoints*) yang tidak terlihat pada *frame*, menandakan bahwa sistem mampu mengenali postur tubuh dengan baik meskipun koordinat sendi tidak lengkap 33 titik.



(b)


Sistem menunjukkan kinerja terbaik dengan akurasi HPE mencapai 100% dan performa maksimal sebesar 1.00. Jarak yang terdeteksi adalah 1.34 meter. Dalam gambar ini, pose tubuh objek berada dalam posisi yang sempurna, sehingga semua titik tubuh dapat dikenali secara utuh oleh sistem. Hal ini menunjukkan bahwa posisi tubuh sangat berpengaruh terhadap hasil estimasi pose yang optimal.



(c)

Gambar 14. Hasil Pengujian Statis

Pada Gambar (c), akurasi HPE mengalami penurunan menjadi 87.88% dengan performa 0.88. Estimasi jarak masih berada di angka yang sama, yaitu 1.34 meter. Penurunan akurasi ini disebabkan oleh posisi tubuh objek yang menyamping, sehingga beberapa titik tubuh tidak terdeteksi dengan sempurna. Meskipun demikian, sistem masih mampu mempertahankan estimasi jarak yang konsisten, menunjukkan keandalan triangulasi meskipun dalam kondisi pose yang tidak ideal.



Gambar 15. Hasil grafik pengujian statis

Dari hasil grafik pengujian statis yang ditampilkan pada Gambar 13 yakni menggambarkan performa sistem dalam

mendeteksi pose manusia dan mengestimasi jarak selama proses pengujian dengan kamera statis dan objek diam pada jarak bervariasi. Tiga parameter yang ditampilkan adalah HPE Accuracy, HPE Performance, dan Human Distance, yang masing-masing direpresentasikan dalam bentuk persentase.

Dari grafik terlihat bahwa HPE Accuracy (garis biru) dan HPE Performance (garis oranye) cenderung stabil dan mendekati 100% sepanjang pengujian. Hal ini menunjukkan bahwa sistem secara umum mampu mendeteksi pose tubuh manusia dengan akurasi dan konsistensi tinggi, terutama saat objek dalam posisi akurat atau jarak optimal terhadap kamera.


3.5. Hasil Pengujian Dinamis

Pengujian ini bertujuan untuk mengevaluasi kemampuan sistem deteksi dan estimasi jarak dalam kondisi dinamis di mana kamera bergerak (misalnya mensimulasikan kereta yang berjalan), dan manusia sebagai objek juga bergerak mendekati kamera. Tujuannya adalah menguji ketahanan sistem terhadap gerakan ganda (kamera dan objek), termasuk perubahan perspektif, pencahayaan, dan kecepatan objek.

Langkah Pengujian :


- 1) Kamera stereo/mono dipasang pada objek bergerak
- 2) Manusia sebagai objek berjalan dari jarak jauh (± 5 meter) menuju ke arah kamera yang juga bergerak perlahan mendekati objek.
- 3) Sistem dijalankan secara real-time:
 - YOLO mendeteksi objek manusia.
 - *BlazePose* mengenali titik-titik pose manusia (*keypoints*).
 - Triangulasi atau *depth estimation* menghitung jarak antara kamera dan objek.
- 4) Hasil estimasi jarak dan hasil deteksi dicatat untuk tiap frame atau jarak tertentu.

Hasil pengujian statis dapat dilihat pada gambar berikut.



(a)

Pada gambar (a), objek manusia berada pada jarak yang cukup jauh dari kamera, yaitu 3.46 meter. Sistem berhasil mendeteksi pose tubuh secara utuh dengan akurasi HPE sebesar 100% dan performanya 1.00, yang menunjukkan bahwa seluruh titik tubuh teridentifikasi dengan jelas dan tepat. Selain manusia, objek lain seperti sepeda motor dan mobil juga berhasil dikenali oleh sistem dengan *bounding box* dan label yang sesuai. Hal ini menunjukkan bahwa dalam kondisi objek diam namun pada jarak jauh, sistem tetap dapat mendeteksi dengan akurat.




(b)

Gambar 16. Hasil Pengujian Dinamis

Sedangkan pada gambar (b), objek manusia telah bergerak lebih dekat ke arah kamera dengan estimasi jarak sebesar 1.26 meter. Namun, akurasi HPE menurun menjadi 81.82% dan performanya menjadi 0.82, yang menunjukkan adanya titik tubuh yang tidak teridentifikasi. Hal ini menunjukkan bahwa pergerakan dinamis dan posisi tubuh yang tidak ideal dapat memengaruhi keakuratan sistem HPE.

Secara keseluruhan, pengujian dinamis ini menunjukkan bahwa sistem mampu mempertahankan performa estimasi jarak yang cukup akurat meskipun objek bergerak, namun akurasi deteksi pose tubuh bisa mengalami penurunan tergantung pada orientasi tubuh, kecepatan gerak, dan kemungkinan terhalangnya titik-titik tubuh dari pandangan kamera.



Gambar 17. Hasil grafik pengujian dinamis

Pada awal grafik, nilai *Human Distance* (garis abu-abu) berada di kisaran 2 meter dan secara bertahap meningkat hingga lebih dari 5 meter, lalu menurun kembali mendekati 0 meter. Ini mencerminkan bahwa objek manusia sempat menjauh terlebih dahulu sebelum akhirnya bergerak mendekati kamera. Objek manusia pada jarak 3.46 meter dengan akurasi HPE sebesar 100% dan performa 1.00 sangat sesuai dengan bagian awal grafik pengujian dinamis, di mana nilai *Human Distance* masih relatif tinggi dan akurasi serta performa HPE stabil di angka maksimal. Ini menunjukkan bahwa pada jarak menengah, sistem mampu mendeteksi seluruh titik tubuh dengan sangat akurat dan menghasilkan estimasi jarak yang konsisten.

Tetapi akurasi pose cenderung menurun ketika objek terlalu dekat atau ketika gerakan terlalu cepat, yang mengganggu proses pendeteksian titik-titik tubuh secara utuh.

IV. KESIMPULAN

Berdasarkan hasil uji coba yang telah dilakukan, percobaan ini berhasil membuat sebuah sistem yang bisa memperkirakan jarak manusia secara langsung (*real-time*) dengan memanfaatkan kombinasi dari YOLO, *blazepose*, dan metode triangulasi *stereo vision*. Sistem ini bekerja dengan menangkap posisi tubuh manusia dari dua sudut kamera, lalu menghitung jaraknya berdasarkan perbedaan posisi titik yang terdeteksi. Berdasarkan analisis gambar dan grafik hasil pengujian, sistem yang dikembangkan menunjukkan

kemampuan yang baik dalam mendeteksi objek dan memperkirakan pose tubuh manusia. YOLOv8 terbukti efektif dalam mengidentifikasi tidak hanya manusia, tetapi juga objek lain seperti kursi dan ponsel, dengan akurasi yang tinggi. Sementara itu, *BlazePose* berhasil dalam mendeteksi keypoints tubuh dan memvisualisasikannya dalam bentuk kerangka, meskipun akurasi detailnya dapat dipengaruhi oleh jarak objek dari kamera. Pengujian statis mengungkapkan bahwa akurasi dan performa estimasi pose tubuh (HPE) cenderung optimal ketika objek dalam keadaan diam dan berada pada jarak yang tepat. Namun, akurasi ini dapat menurun jika ada bagian tubuh yang tidak terdeteksi oleh kamera. Di sisi lain, pengujian dinamis menunjukkan bahwa sistem mampu mempertahankan estimasi jarak yang cukup akurat meskipun terdapat pergerakan kamera dan objek. Akan tetapi, akurasi deteksi pose tubuh dalam kondisi dinamis dapat terpengaruh oleh faktor-faktor seperti kecepatan gerakan dan perubahan sudut pandang.

Dari hasil pengujian yang telah dilakukan, sistem memang bisa memberikan estimasi jarak yang cukup mendekati kondisi sebenarnya, akan tetapi belum bisa dibilang sangat akurat. Selain itu, faktor pencahayaan juga dapat mempengaruhi tingkat akurasi.

and orchard fruit trees. MDPI. DOI: 10.3390/su12103983

- [7] Ramadhan, H. A. Q. (n.d.). IMPLEMENTASI POSE ESTIMATION SEBAGAI MANIPULATOR GERAK TELAPAK TANGAN DENGAN MENGGUNAKAN FRAMEWORK MEDIAPIPE.

REFERENSI

- [1] Al Farhan, S., et al. (2022). Integration of YOLO and Pose Estimation for Real-Time Human Detection and Distance Estimation. *Journal of Robotics and Autonomous Systems*. DOI: 10.1016/j.robot.2022.104295
- [2] Chen, H., Feng, R., Wu, S., Xu, H., Zhou, F., & Liu, Z. (2022). *2D Human Pose Estimation: A Survey* (No. arXiv:2204.07370). arXiv. <https://doi.org/10.48550/arXiv.2204.07370>.
- [3] Dong, C., & Du, G. (2024). An enhanced real-time human pose estimation method based on modified YOLOv8 framework. *Scientific Reports*, 14(1), 8012.
- [4] Kadek, I. G. A. (2023). Implementasi Sistem Estimasi Jarak Objek Menggunakan Metode Triangulasi Stereo pada Sistem Pemantauan Keamanan. Institut Teknologi Bandung. DOI: 10.5614/itb.2023.1.1.1
- [5] N. J. Hayati, D. Singasatia, and M. R. Muttaqin, "Object Tracking Menggunakan Algoritma You Only Look Once (YOLO)v8 untuk Menghitung Kendaraan," *KOMPUTA*, vol. 12, no. 2, pp. 91–99, Nov. 2023, doi: 10.34010/komputa.v12i2.10654
- [6] Nugroho, A., et al. (2020). A review on stereo vision for feature characterization of upland crops

V. LAMPIRAN

Lampiran 1. Standar *Human Pose Estimation* BlazePose

MODEL CARD

MediaPipe BlazePose GHUM 3D

 MODEL DETAILS

Lite (3MB size), Full (6 MB size) and Heavy (26 MB size) models, to estimate the **full 3D body pose** of an individual in videos captured by a **smartphone or web camera**. Optimized for **on-device, real-time fitness applications**: Lite model runs ~44 FPS on a CPU via [XNNPack](#) TFLite and ~49 FPS via TFLite GPU on a Pixel 3. Full model runs ~18 FPS on a CPU via [XNNPack](#) TFLite and ~40 FPS via TFLite GPU on a Pixel 3. Heavy model runs ~4 FPS on a CPU via [XNNPack](#) TFLite and ~19 FPS via TFLite GPU on a Pixel 3.



Depth is encoded via gradient from blue (closer) to green (further). Invisible (occluded) keypoints marked as black.

Returns 33 keypoints describing the approximate location of body parts:

- Nose
- Right eye (3 keypoints): Inner, Center, Outer
- Left eye (3 keypoints): Inner, Center, Outer
- Ears (2 keypoints): Right, Left
- Mouth (2 keypoints): Right Corner, Left Corner
- Shoulder (2 keypoints): Right, Left
- Elbow (2 keypoints): Right, Left
- Wrist (2 keypoints): Right, Left
- Pinky knuckle (2 keypoints): Right, Left
- Index knuckle (2 keypoints): Right, Left
- Thumb knuckle (2 keypoints): Right, Left
- Hip (2 keypoints): Right, Left
- Knee (2 keypoints): Right, Left
- Ankle (2 keypoints): Right, Left
- Heels (2 keypoints): Right, Left
- Foot Index (2 keypoints): Right, Left

 MODEL SPECIFICATIONS

Model Type
Convolutional Neural Network

Model Architecture
Convolutional Neural Network: MobileNetV2-like with customized blocks for real-time performance.

Input(s)
Regions in the video frames where a person has been detected. Represented as a 256x256x3 array with aligned human full body part, centered by mid-hip in vertical body pose and rotation distortion of (-10, 10). Channels order: RGB with values in [0.0, 1.0].

Output(s)

- 33x5 tensor corresponding to screen projected keypoints (x, y, z, visibility, presence).
- 33x3 tensor corresponding to 3D world metric scale coordinates (world x, world y, world z).
- Scalar in range from [0.0, 1.0] corresponding to the presence flag indicating the probability a person is present on a passed image.

For more details about model output ranges and scale consider the “Model outputs detailed specification” section.

Keypoint screen z-value and 3D world x, y, z coordinate values estimate is provided using synthetic data, obtained via the [GHUM model](#) (articulated 3D human shape model) fitted to 2D point projections.

Based on [Model Cards for Model Reporting](#). In Proceedings of FAT* Conference (FAT*2019). ACM, New York, NY, USA



MODEL OUTPUTS DETAILED SPECIFICATION

- X, Y screen projected coordinates are local to the region of interest and range from [0.0, 255.0].
- Z coordinate is measured in "image pixels" like the X and Y screen coordinates and represents the distance relative to the plane of the subject's hips, which is the origin of the Z axis. Negative values are between the hips and the camera; positive values are behind the hips. Z coordinate scale is similar with X, Y scales but has different nature as obtained not via human annotation, by fitting synthetic data ([GHUM model](#)) to the 2D annotation. Note, that Z is not metric but up to scale.
- Visibility is in the range of [min_float, max_float] and after user-applied sigmoid denotes the probability that a keypoint is located within the frame and not occluded by another bigger body part or another object.
- Presence is in the range of [min_float, max_float] and after user-applied sigmoid denotes the probability that a keypoint is located within the frame.
- World X, Y, Z coordinates, representing keypoint location in space, measured in meters and normalized to center of subject hips and range from [-1.5, 1.5]. Whis coordinates obtained not via human annotation, but by fitting synthetic data ([GHUM model](#)) to the 2D annotation, person foreground/background segmentation mask and camera intrinsic parameters.



AUTHORS

Who created this model?

Valentin Bazarevsky, Google
Ivan Grishchenko, Google
Eduard Gabriel Bazavan, Google

DATE

June, 22, 2021



CITATION

How can users cite your model?

BlazePose: On-device Real-time Body Pose tracking, CVPR Workshop on Computer Vision for Augmented and Virtual Reality, Seattle, WA, USA, 2020

GHUM & GHUML: Generative 3D Human Shape and Articulated Pose Models
Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 6184-6193, 2020



DOCUMENTATION

- [BlazePose: On-device Real-time Body Pose tracking](#)
- [GHUM & GHUML: Generative 3D Human Shape and Articulated Pose Models](#)



LICENSED UNDER

[Apache License, Version 2.0](#)

Intended Uses



APPLICATION

3D full body pose estimation for single-person videos on mobile, desktop and in browser.



DOMAIN AND USERS

- Augmented reality
- 3D Pose and gesture recognition
- Fitness and repetition counting
- 3D pose measurements (angles / distances)



OUT-OF-SCOPE APPLICATIONS

- Multiple people in an image.
- People too far away from the camera (e.g. further than 14 feet/4 meters)
- Head is not visible
- Applications requiring metric accurate depth
- Any form of surveillance or identity recognition is explicitly out of scope and not enabled by this technology

Limitations



PRESENCE OF ATTRIBUTES

Tracks only one person on scene if multiple present



TRADE-OFFS

The model is optimized for real-time performance on a wide variety of mobile devices, but is sensitive to face position, scale and orientation in the input image.



ENVIRONMENT

When degrading the environment light, noise, motion or face overlapping conditions one can expect degradation of quality and increase of "jittering" (although we cover such cases during training with real-world samples and augmentations).

Ethical Considerations



HUMAN LIFE

The model is not intended for human life-critical decisions. The primary intended application is entertainment.



PRIVACY

This model was trained and evaluated on images, including consented images (30K), of people using a mobile AR application captured with smartphone cameras in various "in-the-wild" conditions. The majority of training images (85K) capture a wide range of fitness poses.



BIAS

This model was trained and evaluated both on visible and hidden points. For cases where the point location is present but hard to define by a human annotator, it is annotated with a "best guess" and default pose. Model has been qualitatively evaluated on users with missing limbs and prosthetics and degrades gracefully by predicting average point location.

The model is providing 3D coordinates obtained from synthetic data using the GHUM model (articulated 3D human shape model), fitted via an algorithm to the 2D key point projections.

Training Factors and Subgroups



INSTRUMENTATION

- All dataset images were captured on a diverse set of back-facing smartphone cameras.
- All images were captured in a real-world environment with different light, noise and motion conditions via an AR (Augmented Reality) application.



ENVIRONMENTS

Model is trained on images with various lighting, noise and motion conditions and with diverse augmentations. However, its quality can degrade in extreme conditions. This may lead to increased "jittering" (inter-frame prediction noise).



ATTRIBUTES


- Human Full-body cropped from the captured frame should contain a single person placed in the center of the image.
- There should be a margin around the square circumscribing full-body calculated as 25% of size.
- Model is tolerant to certain level of input inaccuracy:
 - 10% shift and scale (taking body width/height as 100% for corresponding axis)
 - 8° roll



GROUPS

To perform fairness evaluation we group user samples into 14 evenly distributed geographic subregions (based on [United Nations geoscheme](#) with merges):

Central America	Caribbean
Southern America	Northern America
Central Asia	Northern Africa
Eastern Asia	Middle Africa
Southeastern Asia	Southern Africa
Southern Asia	Australia and New Zealand
Western Asia	Europe (excluding EU)




Evaluation modes and metrics

Evaluation Modes



TRACKING MODE

Main mode that takes place most of the time and is based on obtaining a highly accurate full-body crop from the prediction on the previous frame (frames 2, 3, ... on the image)



Model Performance Measures

PDJ, Average percentage of detected joints
(Also known as PCK@0.2 - Percent of Correct Keypoints)

<https://github.com/cbsudux/Human-Pose-Estimation-101>

We consider a keypoint to be correctly detected if predicted visibility for it matches ground truth and the absolute 2D Euclidean error between the reference and target keypoint normalized by the 2D torso diameter projection is smaller than 20%. This value was determined during development as the maximum value that does not degrade accuracy in classifying pose / asana based solely on the key points without perceiving the original RGB image.

The model is providing 3D coordinates, but the screen z-coordinate, as well as world 3D coordinates obtained from synthetic data, so for a fair comparison with human annotations, only 2D screen coordinates are employed.

Evaluation results

Geographical Evaluation Results



DATA

- Contains 1400 samples evenly distributed across 14 geographical subregions (see specification in Section "Factors and Subgroups"). Each region contains 100 images.
- All samples are picked from the same source as training samples and are characterized as smartphone back-facing camera photos taken in real-world environments (see specification in "Factors and Subgroups - Instrumentation").



EVALUATION RESULTS

Detailed evaluation for the tracking modes across 14 geographical subregions, gender and skin tones is presented in the table below

Region	Lite model		Full model		Heavy model	
	PDJ	Standard deviation	PDJ	Standard deviation	PDJ	Standard deviation
Australia and New Zealand	94.1	8.3	95.4	7.6	98.0	3.9
Caribbean	94.8	8.3	97.7	4.9	98.9	2.9
Europe	90.3	12.6	95.1	8.4	97.8	4.8
Northern Africa	94.7	8.2	97.7	5.2	98.9	3.3
South America	95.0	8.3	97.8	4.8	99.0	3.0
Southeastern Asia	94.5	8.1	97.1	5.1	98.5	3.9
Western Asia	94.9	7.8	97.7	5.6	99.0	2.9
Central America	95.4	6.5	97.6	4.5	98.6	2.9
Central Asia	94.3	8.7	96.8	5.4	97.9	4.7
Eastern Asia	91.3	12.5	94.6	8.3	97.4	5.1
Middle Africa	94.6	9.5	96.6	6.6	98.3	4.6
Northern America	93.4	8.6	96.2	6.3	98.7	3.3
Southern Africa	92.9	10.0	95.1	6.9	97.0	6.3
Southern Asia	93.4	9.0	96.8	6.2	98.2	4.5
Average	93.8		96.6		98.3	
Range	5.1		3.2		2.0	

Geographical Fairness Evaluation Results



FAIRNESS CRITERIA

We consider a model to be performing unfairly across representative groups if the error range on them spans more than ~3x the human annotation discrepancy, in our case a total of **7.5% PDJ**.



FAIRNESS METRICS & BASELINE

We asked two annotators to re-annotate the Pose Validation dataset, yielding a PDJ of **97.5%**. This is a high inter-annotator agreement, suggesting that the PDJ metric is a strong indicator of precise matches between predicted keypoints and ground truth keypoints.



FAIRNESS RESULTS

Evaluation across 14 regions of heavy, full and lite models on smartphone back-facing camera photos dataset results an average performance of 98.3% +/- 0.6% stdev with a range of [97.0%, 99.0%] across regions for the heavy model, an average performance of 96.6% +/- 1.3% stdev with a range of [94.6%, 97.8%] across regions for the full model and an average performance of 93.8% +/- 1.5% stdev with a range of [90.3%, 95.4%] across regions for the lite model.

Comparison with our fairness criteria yields a maximum discrepancy between average and worst performing regions of 2.0% for the heavy, 3.2% for the full and 5.1% for the light model.

Skin Tone and Gender Evaluation Results



DATA

- **1400 images, 100 images from each of 14 the geographical subregions** were annotated with perceived gender and skin tone (from 1 to 6) based on the Fitzpatrick scale.



EVALUATION RESULTS

Evaluation on smartphone back-facing camera photos dataset results in an average performance of 98.2% with a range of [97.7%, 98.8%] across all skin tones for the heavy model, an average performance of 96.3% with a range of [94.7%, 97.1%] across all skin tones for the full model and an average performance of 94.2% with a range of [91.4%, 96.3%] across regions for the lite model. The maximum discrepancy between worst and best performing categories is 1.1% for the heavy model, 2.5% for the full model and 4.9% for the lite model.

Evaluation across gender yields an average performance of 98.9% with a range of [97.9%, 98.9%] for the heavy model, an average performance of 96.7% with a range of [96.0%, 97.3%] for the full model, and an average of 93.9% with a range of [93.1%, 94.7%] for the lite model. The maximum discrepancy is 1.0% for the heavy model, 1.3% for the full model and 1.6% for the lite model.

Skin tone type	% of dataset	Lite model		Full model		Heavy model	
		PDJ	Standard deviation	PDJ	Standard deviation	PDJ	Standard deviation
1	1.3	96.3	2.5	95.1	5.5	98.8	1.4
2	9.5	91.4	10.1	94.7	7.7	97.7	4.2
3	34.3	93.9	9.3	96.7	6.1	98.2	4.4
4	36.2	94.3	9.0	97.0	6.2	98.6	3.9
5	14.2	94.5	9.3	97.2	5.5	98.5	3.9
6	4.5	96.1	7.1	97.1	5.8	98.7	3.7
Average		94.2		96.3		98.2	
Range		4.9		2.5		1.1	

Gender	% of dataset	Lite model		Full model		Heavy model	
		PDJ	Standard deviation	PDJ	Standard deviation	PDJ	Standard deviation
Male	45.9	94.7	9.0	97.3	5.67	98.9	3.5
Female	54.1	93.1	9.5	96.0	6.80	97.9	4.7
Average		93.9		96.7		98.4	
Range		1.6		1.3		1.0	

Definitions

AUGMENTED REALITY (AR)

Augmented reality, a technology that superimposes a computer-generated image on a user's view of the real world, thus providing a composite view.

PERSPECTIVE PROJECTION

[Perspective projection](#) or perspective transformation is a linear projection where three dimensional objects are projected on a picture plane.

KEYPOINTS

"Keypoints" or "landmarks" are (x, y, z) coordinate locations of body parts.

In this model we separate key points into two groups:

- Screen landmarks - coordinate locations of body parts projected to the users screen.
- World landmarks - coordinate locations in the real world 3D space

VISIBILITY

Visibility denotes the probability that a keypoint is located within the frame and not occluded either by other body parts or other objects.

PRESENCE

Presence denotes the probability that a keypoint is located within the frame. It does not indicate whether the keypoint is occluded by another body part.